TECNICATURA UNIVERSITARIA EN INTELIGENCIA ARTIFICIAL

Universidad Nacional de Hurlingham

PROYECTO INTEGRADOR

¿Más datos siempre producen un mejor modelo? Un estudio experimental sobre el tamaño del conjunto de entrenamiento, la calidad de los datos y el rendimiento en clasificación supervisada

Docente tutor: Sebastián Matias Paez

Estudiante: _____

Cuatrimestre / Año: _____

1. Fundamentación

Una de las creencias más extendidas —dentro y fuera de la comunidad de Inteligencia Artificial— es que "más datos siempre son mejores". Gran parte de la narrativa pública sobre los grandes modelos de lenguaje y de visión se apoya en esta idea: cuanto más grande el dataset, mejor el modelo. Sin embargo, la relación entre el volumen de datos de entrenamiento y el desempeño de un modelo no es lineal, no es universal para cualquier problema o algoritmo, y está condicionada por factores como la calidad de los datos, la complejidad del modelo elegido y el tipo de tarea a resolver.

Este Proyecto Integrador propone abordar esa pregunta de forma empírica y metodológicamente rigurosa, integrando contenidos de Probabilidad y Estadística (inferencia, intervalos de confianza, ensayos de hipótesis), Fundamentos de Ciencias de Datos (manipulación y análisis exploratorio de datos) y Aprendizaje Automático (clasificadores, métricas de evaluación, validación de modelos), tal como lo requiere el Campo de Integración Curricular de la carrera.

A diferencia de un ejercicio de aula, el proyecto no se limita a entrenar un modelo con distintos porcentajes de datos y graficar el resultado: exige diseñar un experimento controlado, repetible y estadísticamente defendible, y discutir sus resultados con espíritu crítico. Esto acerca la propuesta a una práctica real de un/a Técnico/a en IA, cuyo perfil de egreso incluye "evaluar la calidad de los modelos desarrollados" y "aplicar criterios de calidad, privacidad, seguridad y gobernanza de datos" en todos los procesos en los que interviene.

2. Pregunta de investigación

"¿Cuál es el impacto real del tamaño y la calidad del conjunto de entrenamiento sobre el desempeño de un modelo de clasificación supervisada, y a partir de qué punto los datos adicionales dejan de justificar su costo?"

Esta pregunta general se descompone en tres sub-preguntas que el/la estudiante deberá responder con evidencia empírica:

1. ¿Cómo evolucionan accuracy, precision, recall y F1-score a medida que aumenta el porcentaje de datos de entrenamiento utilizado?
2. ¿Ese comportamiento es el mismo para modelos de distinta complejidad (por ejemplo, un modelo lineal simple frente a un ensamble o una red neuronal)?
3. ¿"Más datos" es siempre preferible a "mejores datos"? Es decir, ¿un modelo entrenado con menos datos pero más limpios puede igualar o superar a uno entrenado con más datos pero más ruidosos?

3. Objetivos

3.1 Objetivo general

Evaluar experimentalmente el efecto del tamaño y la calidad del conjunto de entrenamiento sobre el desempeño de modelos de clasificación supervisada, mediante un diseño experimental estadísticamente riguroso y reproducible.

3.2 Objetivos específicos

- Construir un pipeline reproducible de preparación de datos, entrenamiento y evaluación para al menos un dataset de clasificación.
- Entrenar y evaluar el/los modelo(s) elegido(s) sobre subconjuntos de entrenamiento de 20%, 40%, 60%, 80% y 100% del dataset, repitiendo cada punto con múltiples muestreos aleatorios.
- Calcular, para cada tamaño de entrenamiento, medidas de tendencia central y de dispersión (media, desvío estándar, intervalo de confianza) de accuracy, precision, recall y F1-score.
- Determinar si las diferencias observadas entre tamaños de dataset son estadísticamente significativas o podrían explicarse por variabilidad aleatoria del muestreo.
- Ajustar una curva de aprendizaje (learning curve) a los resultados y estimar el punto de "retornos decrecientes", es decir, a partir de qué tamaño de dataset el aumento de datos deja de traducirse en una mejora relevante de desempeño.
- Comparar el efecto de la cantidad de datos frente al efecto de la calidad de los datos (introduciendo ruido controlado en las etiquetas o en los atributos), para discutir la disyuntiva "cantidad vs. calidad".
- Analizar el costo computacional (tiempo de entrenamiento) asociado a cada escenario y contrastarlo con la mejora de desempeño obtenida.
- Comunicar los resultados en un informe técnico y una exposición final, con conclusiones fundamentadas y limitaciones explicitadas.

4. Nota para el/la estudiante

Este proyecto no busca una respuesta única ni "correcta": busca que puedas sostener, con evidencia y con criterio estadístico, una conclusión propia sobre cuánto dato hace falta para tu problema particular, y bajo qué condiciones. Las conclusiones más valiosas suelen ser matizadas ("depende de X") y no absolutas ("siempre" o "nunca"). Se espera honestidad respecto de las limitaciones del propio diseño experimental (por ejemplo, un único dataset no permite generalizar a todos los problemas de clasificación).